

실험 리포트 — LLM 제공자 비교 실험 (로컬 LLM · 오픈 가중치 모델)

항목	내용
실험일	2026-09-17
목적	2026-09-21 팀 회의 안건. Gemini(학교 게이트웨이) 의존을 줄일 대안으로 로컬 LLM(Qwen 등)과 오픈 가중치 모델(Kimi 등)을 검토
결정용 요약	<code>../llm-provider-evaluation-2026-09.md</code>
실험 도구	<code>ai/scripts/llm_eval/</code>
원시 데이터	이 디렉터리의 <code>raw/*.jsonl</code> , <code>auto-metrics-summary.json</code> , <code>eval-judge.jsonl</code> , <code>eval-judge-table.json</code> , <code>gpu-placement.log</code>

0. 한 줄 결론

운영은 현재 게이트웨이 **Gemini(3.5 Flash-Lite + 3.1 Pro)**를 유지한다. ana-server(GTX 1660 Ti 6GB)의 로컬 LLM은 품질이 절반 수준(블라인드 채점 1.6~2.7 vs 4.0)이고, GPU 1장의 직렬 처리 때문에 동시 사용 시 꼬리질문이 33~111초로 무너져 운영 대체가 불가능하다. 게이트웨이 대비책으로는 Gemma 4 31B(품질 동급, 느림)와 Solar Pro 4(빠름, 프롬프트 보정 필요)가 유력하다.

1. 배경과 질문

StackUp의 AI 서버는 두 티어로 LLM을 쓴다.

티어	현재 모델	쓰이는 곳	요구사항
Pro	gemini-3.1-pro-preview	질문 풀 생성, 피드백 패널·종합, PDF 비전	품질, JSON 스키마 준수, 멀티모달(PDF)
Flash	gemini-3.5-flash-lite	스트리밍 꼬리질문(+답변 의도 분류·채점), 자기소개 평가, 답변 코칭(세션당 ~15건, 동시 5)	저지연(< 3s), 태그 출력 준수

두 티어 모두 학교 발급 키로 OpenAI 호환 게이트웨이(Mindlogic)를 경유한다. 이번 실험은 다음 질문에 답한다.

- 이 서버의 GPU로 Qwen 같은 로컬 모델을 돌려 Gemini를 대체할 수 있는가?
- Kimi-Qwen 같은 오픈 가중치 대형 모델은 현실적인 대안인가?
- 게이트웨이를 못 쓰게 되면 무엇으로, 얼마에 갈 수 있는가?

2. 실험 환경

2.1 하드웨어·소프트웨어

항목	값
서버	ana-server — Intel i7-10750H (12 스레드), RAM 16GB (가용 ~11GB)
GPU	NVIDIA GeForce GTX 1660 Ti 6GB (Turing), 드라이버 575.57.08 / CUDA 12.9
로컬 서빙	Ollama 0.20.7 (Docker, 다른 프로젝트 devlog.devtalk.mcp와 공유), OpenAI 호환 <code>/v1/chat/completions</code>

항목	값
로컬 모델 설정	전 모델 <code>PARAMETER num_ctx 8192</code> 파생 모델 생성, 측정 전 워밍업
실행 위치	운영 <code>stackup-ai</code> 컨테이너 안 (운영과 같은 의존성-네트워크). Ollama 컨테이너를 <code>stackup_default</code> 네트워크에 연결
게이트웨이	factchat-cloud.mindlogic.ai (학교 키). 지연 수치에 게이트웨이 오버헤드 포함

2.2 운영 부하 기준값 (운영 DB 집계, 개인 데이터 미열람)

실험 입력 크기와 동시성 조건을 정하기 위해 `ai_request_logs` · `interview_messages` 를 집계만 했다.

지표	값
질문 풀 생성 입력 토큰	p50 3,141 / p90 4,722 / max 4,869
질문 풀 생성 지연 (Gemini 3.1 Pro)	p50 14.4s / p90 16.9s
꼬리질문 스트림 지연 (Gemini Flash-Lite)	p50 1.6s
피드백 코칭 입력/출력 토큰	평균 ~2,000 / ~420
피드백 패널(Pro) 지연	p50 12.2s / p90 19.4s
지원자 답변 길이	p50 162자 / p90 425자 / max 2,583자
누적 사용량	세션 95건, 사용자 4명 (2026-05~09)

3. 후보 모델 선정

3.1 사전 조사 요약 (웹 리서치, 2026-09 기준)

구분	모델	요점
6GB 에 들어가는 소형	Qwen3 4B Instruct-2507	기존 1차 후보. Apache-2.0
	Qwen3.5 4B	최신 소형 Qwen, 비전 포함, thinking 기본 on
	Kanana-2-3B (카카오)	3B급 한국어 벤치 최상위(KMMLU 43.3, KoMT 6.92). 자사 서비스 사용 가능 라이선스
	Mi:dm 2.0 Mini (KT)	2.3B, MIT, Ko-IFEval 73.3
	A.X 4.0 Light (SKT)	7B, Apache-2.0, KMMLU 64.2. Q4 ~4.7GB 로 빠듯
	Gemma 4 E2B	대조군. thinking 기본 on
	EXAONE 3.5/4.0 (LG)	비상업 라이선스 → 운영 후보에서 제외 (1차 측정만)
Kimi	K2.6 (1T/32B active), K3 (2.8T/104B active), Kimi-Linear 48B	로컬 불가 (최소 Kimi-Linear Q2 도 16GB+). API 는 K2.6 \$0.95/\$4.00, K3 \$3/\$15 (per 1M)
대형 오픈 (API)	Qwen3.8-Flash, DeepSeek V4.1 Flash, GLM-5.3-Flash, gpt-oss-120b	가격은 Gemini 대비 수 분의 1. 한국어 공개 벤치 부족
게이트웨이에 이미 있음	Gemma 4 31B, Solar Pro 4, gpt-oss-120b, Llama 4 Maverick	학교 키로 바로 실행 가능 → 포함

게이트웨이 `/models` 에는 75개 모델이 있었으나 Qwen·Kimi·DeepSeek 는 없었다. 외부 API 키가 없어 이 셋은 **실행하지 못했다**.

3.2 최종 실측 대상

경로	모델	설정
게이트웨이 (기준)	gemini-3.5-flash-lite	운영값
게이트웨이 (기준)	gemini-3.1-pro-preview	질문 풀만
게이트웨이	google/gemma-4-31B-it	운영 프롬프트 그대로
게이트웨이	solar-pro4	//
게이트웨이	gpt-oss-120b (Fireworks)	운영값 512 토큰 + 재측정 2048 토큰
게이트웨이	Llama-4-Maverick-17B-128E-Instruct-FP8	//
로컬	qwen3:4b-instruct	num_ctx 8192
로컬	qwen3.5:4b	num_ctx 8192, reasoning_effort: none
로컬	kanana-2-3b-instruct Q4_K_M (GGUF)	num_ctx 8192
로컬	Midm-2.0-Mini-Instruct Q4_K_M (GGUF)	num_ctx 8192
로컬	A.X-4.0-Light Q4_K_M (GGUF)	num_ctx 8192
로컬 (실패)	gemma4:e2b-it-qat	Ollama 0.20.7 에서 pull 불가(업그레이드 요구). 공유 컨테이너라 미업그레이드

4. 실험 방법

4.1 원칙

- **운영 코드를 그대로 쓴다.** 프롬프트·파서·체인 빌더를 수정하지 않고 모델·엔드포인트만 바꿨다.
 - 질문 풀: `build_question_generation_chain` (PydanticOutputParser, JSON)
 - 꼬리질문: `build_streaming_followup_generator().stream()` (운영 경로, `<intent>/<question>/<meta>` 태그, 첫 질문 토큰 시점 측정)
 - 코칭: `build_answer_coaching_chain` (JSON)
- **합성 데이터만 쓴다.** 실제 사용자 이력서·답변은 쓰지 않았다.

4.2 테스트 케이스 (cases.py)

질문 풀 5건 (각 2회 반복)

ID	직군 / 모드	자료	확인하려는 것
q-backend-tech	BACKEND / TECHNICAL	이력서 + 자기소개	자기소개 앵커링, 근거 인용
q-frontend-repo	FRONTEND / TECHNICAL	GitHub 레포 분석	레포 기반 질문
q-infra-dba-multi	INFRA+DBA / INTEGRATED	이력서	복수 직군 분배, 카테고리 균형
q-personality-coverletter	BACKEND / PERSONALITY	자소서	BEHAVIORAL 중심, STAR 유도
q-long-context-p90	BACKEND / TECHNICAL	문서 4개(운영 p90 크기) + 최근 질문 2개	긴 문맥 절단, 최근 질문 중복 회피

꼬리질문 14건 (각 3회 반복, 정답 라벨 포함)

ID	상황	정답 의도	점수 기대	correctness 기대
f-strong-backend	구체 수치·원인 포함 좋은 답	NORMAL	높음(≥3)	null (컨텍스트 없음)
f-weak-vague	"잘 처리했습니다" 식 부실한 답	NORMAL	낮음(≤2)	null
f-dont-know-explicit	"잘 모르겠습니다, 넘어가도 될까요"	DONT_KNOW	—	null
f-dont-know-stt	STT 간투어 섞인 "모르겠어요"	DONT_KNOW	—	null
f-clarification	"질문을 쉽게 다시 말씀해 주세요"	CLARIFICATION	—	null
f-confirm-short	확인형 질문에 "네, 맞습니다"	NORMAL	null (감점 금지)	null
f-infra-fact-error	이력서(CPU 70%)와 다른 답(메모리 50%)	NORMAL	낮음	낮음(≤2)
f-dba-correct-with-context	이력서와 일치하는 좋은 답	NORMAL	높음	높음(≥3)
f-frontend-strong	레포와 일치하는 좋은 답	NORMAL	높음	높음
f-personality-star	STAR 구조 경험 답변	NORMAL	높음	null
f-personality-rambling	두루뭉술한 인성 답변	NORMAL	낮음	null
f-stt-messy-normal	간투어 많지만 내용 좋은 STT 답	NORMAL	높음	null
f-long-answer-history	1,000자 답변 + 대화 이력 2턴	NORMAL	높음	null
f-english-mixed	영문 기술용어 섞인 답	NORMAL	높음	null

코칭 3건 (각 3회 반복): 부실한 기술 답변, "모름" 답변, 두루뭉술한 인성 답변.

4.3 지연·동시성 시나리오 (--latency)

- 콜드스타트:** Ollama 에서 모델 언로드 (`keep_alive: 0`) 후 첫 꼬리질문, 그다음 호출.
- 피드백 fan-out:** 코칭 15건을 동시성 5 로 실행 (운영 `FEEDBACK_COACHING_CONCURRENCY=5` , 세션당 ~15건과 동일).
- 경합:** fan-out 시작 3초 뒤 "다른 사용자"의 꼬리질문 1건 → 그 지연.

4.4 자동 지표 (`analyze.py` , 규칙 기반)

지표	정의
태그 준수	꼬리질문에 태그 잔해가 없고, NORMAL 답변이면 <code><meta></code> 평가가 파싱됨 (확인형 단답은 meta 없어도 준수)
의도 분류 정확도	<code>answer_intent</code> 가 라벨과 일치한 비율
점수 라벨 정확도	NORMAL 케이스에서 specificity 가 기대(높음 ≥3 / 낮음 ≤2 / null)와 일치
사실대조 규칙	correctness 가 기대(컨텍스트 없으면 null / 불일치면 ≤2 / 일치면 ≥3)와 일치
판별력	같은 질문의 강한 답 - 약한 답 specificity 중간값 차
질문 풀 성공	JSON 파싱 성공 비율
근거 인용 실재	<code>target_evidence</code> 의 4-gram 60% 이상이 자료 원문에 존재
중복	같은 풀 안 질문쌍 문자 bigram Jaccard ≥ 0.5
외국 문자	한자·가나·키릴·태국·아랍 문자 혼입
코칭 수치 날조	모범답안·리라이트에 자료·답변에 없는 2자리 이상 수치
지연	총 지연 중간값: p90, 첫 질문 토큰(TTFT), 3초·10초(운영 타임아웃) 초과 비율

4.5 블라인드 품질 채점 (`judge.py`)

- 같은 케이스에 대한 후보들의 출력(반복 0회차)을 **익명 A, B, C...** 로 묶고 판정 호출마다 **순서를 무작위로** 섞었다.
- 판정 모델: **gemini-3.1-pro-preview**, **claude-opus-5** (서로 다른 계열, temperature 0). 판정 호출 44건, 오류 0.
- 채점 축 (1~5):

- 꼬리질문: relevance(답변 특정 대목·의도 대응), depth(기대 신호 겨냥·변별력), language(한국어·간결), overall
 - 질문 풀: grounding(자료 근거·날조 없음), coverage(주제·직군·모드 분배), depth, language, overall
 - 코칭: usefulness, faithfulness(날조 없음), rewrite(원 답변 기반), language, overall
- 제외: Kanana-2-3B (출력 자체가 깨져 채점 의미 없음).

5. 결과

5.1 블라인드 품질 — overall

모델	꼬리질문 Claude / Gemini / 평균	질문 풀 Claude / Gemini / 평균	코칭 Claude / Gemini / 평균
Gemini 3.1 Pro	—	4.4 / 4.6 / 4.5	—
Gemini 3.5 Flash-Lite	4.0 / 4.4 / 4.2	4.2 / 4.2 / 4.2	4.3 / 4.0 / 4.2
Gemma 4 31B	3.9 / 4.9 / 4.4	4.0 / 4.6 / 4.3	4.0 / 4.7 / 4.3
Solar Pro 4	3.8 / 3.4 / 3.6	3.8 / 3.0 / 3.4	4.7 / 4.0 / 4.3
gpt-oss-120b	3.3 / 3.0 / 3.1	2.4 / 3.0 / 2.7	2.7 / 2.0 / 2.3
Llama 4 Maverick	3.3 / 2.7 / 3.0	2.8 / 1.8 / 2.3	3.0 / 2.3 / 2.7
Qwen3 4B Instruct (로컬)	2.6 / 2.4 / 2.5	3.0 / 3.2 / 3.1	2.3 / 2.0 / 2.2
Qwen3.5 4B (로컬)	2.7 / 2.2 / 2.5	2.7 / 2.3 / 2.5	2.0 / 1.7 / 1.8
A.X 4.0 Light (로컬)	2.1 / 1.7 / 1.9	2.7 / 2.3 / 2.5	2.3 / 2.0 / 2.2
Mi:dm 2.0 Mini (로컬)	1.6 / 1.4 / 1.5	2.0 / 2.0 / 2.0	전부 파싱 실패

판정자 신뢰도

- 같은 (케이스, 모델) 192쌍에서 두 판정자 overall 완전 일치 38.5%, **±1점 이내 90.1%**, 평균 절대차 0.71.
- **Gemini 판정자는 Google 계열에 후했다**: 꼬리질문 Gemma 4 31B +0.93, Gemini Flash-Lite +0.43, 질문 풀 Gemma +0.6 (Claude 대비). 반대로 Solar-Llama 는 Gemini 판정자가 더 낮게 줬다. → **순위 판단은 Claude 점수를 우선했다**.

5.2 블라인드 품질 — 세부 축 (Claude 판정)

꼬리질문

모델	relevance	depth	language	overall
Gemini 3.5 Flash-Lite	4.57	3.71	4.50	4.00
Gemma 4 31B	4.36	3.71	4.71	3.93
Solar Pro 4	4.21	4.00	3.36	3.79
gpt-oss-120b	3.43	3.07	4.43	3.29
Llama 4 Maverick	3.64	2.93	4.64	3.29
Qwen3.5 4B	3.36	2.71	3.93	2.71
Qwen3 4B Instruct	3.14	2.21	3.43	2.57
A.X 4.0 Light	2.36	1.79	3.57	2.14
Mi:dm 2.0 Mini	1.79	2.07	3.29	1.64

질문 풀

모델	grounding	coverage	depth	language	overall
Gemini 3.1 Pro	5.00	4.60	4.60	4.40	4.40
Gemini 3.5 Flash-Lite	4.80	4.20	4.00	4.60	4.20
Gemma 4 31B	4.80	3.60	4.00	5.00	4.00
Solar Pro 4	4.60	3.80	4.60	3.00	3.80
Qwen3 4B Instruct	4.20	3.40	3.00	3.40	3.00
Llama 4 Maverick	3.80	3.20	2.20	4.00	2.80
Qwen3.5 4B	3.67	3.00	3.33	2.67	2.67
A.X 4.0 Light	3.00	2.33	2.67	3.33	2.67
gpt-oss-120b	3.40	3.20	2.40	3.80	2.40
Mi:dm 2.0 Mini	2.00	2.00	2.00	4.00	2.00

코칭

모델	usefulness	faithfulness	rewrite	language	overall
Solar Pro 4	4.67	4.67	4.67	5.00	4.67
Gemini 3.5 Flash-Lite	4.33	4.67	4.33	5.00	4.33
Gemma 4 31B	4.00	4.33	4.33	4.67	4.00
Llama 4 Maverick	3.00	4.00	2.67	4.00	3.00
gpt-oss-120b	3.67	3.00	3.00	3.33	2.67
Qwen3 4B Instruct	2.67	3.33	2.33	3.33	2.33
A.X 4.0 Light	2.33	3.33	2.33	3.33	2.33
Qwen3.5 4B	2.33	3.33	2.33	2.33	2.00

5.3 꼬리질문 케이스별 품질 (두 판정자 평균 overall)

케이스	Gemini FL	Gemma 31B	Solar Pro 4	gpt-oss	Llama 4	Qwen3 4B	Qwen3.5 4B	A.X Light	Mi:dm Mini
f-strong-backend	3.5	4.5	4.5	2.0	4.0	1.5	2.0	1.5	1.0
f-weak-vague	4.0	4.5	2.0	3.0	2.5	4.0	3.0	2.0	2.0
f-dont-know-explicit	5.0	4.5	2.0	1.0	3.0	1.0	1.5	1.5	1.0
f-dont-know-stt	4.0	4.5	1.5	1.5	3.5	1.0	2.0	1.5	1.5
f-clarification	4.5	4.5	2.0	4.5	3.0	2.5	2.0	2.5	1.5
f-confirm-short	4.5	3.5	4.5	3.5	2.5	1.0	2.0	2.5	2.0
f-infra-fact-error	5.0	5.0	3.0	3.0	3.0	2.5	4.0	1.5	1.5
f-dba-correct-with-context	3.5	4.5	2.5	4.0	4.0	3.0	1.5	1.5	1.5
f-frontend-strong	3.5	4.0	4.5	5.0	3.0	3.5	2.5	2.0	1.5
f-personality-star	4.5	4.5	5.0	3.5	2.5	2.0	2.5	2.0	1.5
f-personality-rambling	4.5	5.0	4.0	3.0	3.0	5.0	4.0	3.5	2.0
f-stt-messy-normal	4.5	4.5	4.5	3.5	3.0	3.5	2.5	2.0	1.0
f-long-answer-history	4.5	4.0	5.0	2.5	1.5	1.5	2.0	1.5	1.0
f-english-mixed	3.5	4.0	5.0	4.0	3.5	3.0	3.0	1.5	2.0

gpt-oss-120b 는 max_tokens 512 의 반복 0회차 출력으로 채점되지 않도록 2048 재측정 결과로 채점했다.

관찰:

- **Solar Pro 4** 는 정상 답변에서 최상급(긴 답변·STAR·영문 혼용 5.0)이지만 "모름"·재설명 요청 대응이 약하다(1.5~2.0). 재설명 대신 정답 요소를 나열하거나, 부실한 답을 DONT_KNOW 로 분류했다.

- **Gemini Flash-Lite** 와 **Gemma 31B** 는 모든 유형에서 고르게 3.5 이상.
- 로컬 소형 모델은 "모름"·재설명·확인형 단답 대응이 1.0~2.5 로 가장 약하다. 운영에서 가장 흔한 흐름(짧은 답·모름)에서 면접 경험이 망가진다.

5.4 형식 준수·채점 신뢰도 (자동 지표)

모델	호출 성공	태그 준수	의도 분류	점수 라벨	사실대조 규칙	판별력(백엔드/인성)	질문 풀 성공	긴 문맥 풀	근거 인용 실재	코칭 성공
Gemini 3.1 Pro	—	—	—	—	—	—	100%	2/2	100%	—
Gemini 3.5 Flash-Lite	100%	100%	100%	100%	100%	3.0 / 2.0	90%	1/2	100%	100%
Gemma 4 31B	100%	100%	100%	100%	100%	3.0 / 3.0	100%	2/2	100%	100%
Solar Pro 4	100%	100%	95.2%	87.9%	100%	2.0 / 2.0	100%	2/2	100%	100%
gpt-oss-120b (512)	100%	54.8%	100%	42.4%	72.7%	4.0 / —	100%	2/2	100%	100%
gpt-oss-120b (2048)	100%	100%	100%	100%	100%	—	—	—	—	—
Llama 4 Maverick	100%	100%	92.9%	90.9%	81.8%	3.0 / 2.0	100%	2/2	100%	100%
Qwen3 4B Instruct	100%	100%	100%	81.8%	57.6%	2.0 / 2.0	90%	2/2	100%	100%
Qwen3.5 4B	100%	33.3%	92.9%	18.2%	69.7%	2.0 / —	50%	0/2	100%	100%
A.X 4.0 Light	100%	100%	90.5%	75.8%	54.5%	3.0 / 1.0	70%	1/2	91.4%	88.9%
Mi:dm 2.0 Mini	100%	28.6%	14.3%	9.1%	72.7%	—	30%	1/2	100%	0%
Kanana-2-3B	출력 깨짐	28.6%	78.6%	9.1%	72.7%	—	0%	0/2	—	0%

추가 지표:

- **외국 문자 혼입**: 모든 모델 0% (Qwen 계열의 중국어 혼입 우려는 이번 케이스에서 관찰되지 않음).
- **마크다운 기호 혼입(질문)**: 모든 모델 0%.
- **질문 풀 내 중복 질문쌍**: 모든 모델 0%. 최근 받은 질문 반복은 Mi:dm 1건.
- **코칭 수치 날조**: gpt-oss-120b 11.1%, 나머지 0%.
- **질문 길이** (질문 풀, 80자 이내 비율): Llama 4·gpt-oss 96%, Gemma 85%, Qwen3 4B 53%, Gemini Flash-Lite 45%, Gemini Pro 17%, **Solar Pro 4 0%** (중간값 117자, 최대 203자).

의도 분류 오답 패턴:

- Mi:dm 2.0 Mini: **42건 전부 DONT_KNOW**. 운영에서 DONT_KNOW 꼬리질문은 Core 가 폐기하므로 면접이 진행되지 않는다.
- Kanana-2-3B: 42건 전부 NORMAL (모름·재설명 인식 불가) + 출력 문자열 깨짐.
- Solar Pro 4 / Llama 4 / A.X: 부실한 답(f-weak-vague)을 DONT_KNOW 로 분류하는 경향.
- Qwen3.5 4B: 두루뭉술한 인성 답변을 CLARIFICATION 으로 1회 분류.

질문 풀 실패 원인:

- Gemini Flash-Lite 1건: 긴 문맥 케이스에서 JSON 코드펜스 출력 파싱 실패.
- Qwen3.5 4B: `{"questions": [...]}` 대신 **배열만 출력**해 스키마 불일치 (5건).
- A.X·Mi:dm: JSON 은 나왔으나 스키마 검증 실패.
- Kanana-2-3B: "관 관 관..." 같은 깨진 토큰 반복.

5.5 지연

모델	꼬리질문 중간값 / p90	첫 질문 토큰 중간값	3초 초과	10초 초과	질문 풀 중간값 / p90	코칭 중간값
Gemini 3.5 Flash-Lite	2.04 / 5.82s	1.54s	16.7%	0%	4.19 / 4.68s	3.03s
Gemini 3.1 Pro	—	—	—	—	24.74 / 26.52s	—
Gemma 4 31B	9.16 / 54.28s	3.18s	100%	47.6%	43.68 / 50.06s	22.56s
Solar Pro 4	2.32 / 4.43s	1.30s	23.8%	0%	16.23 / 21.14s	5.32s
gpt-oss-120b (2048)	4.25 / 5.54s	3.91s	97.6%	0%	15.38 / 17.68s	8.88s

모델	꼬리질문 중간값 / p90	첫 질문 토큰 중간값	3초 초과	10초 초과	질문 풀 중간값 / p90	코칭 중간값
Llama 4 Maverick	1.85 / 2.75s	1.32s	0%	0%	7.27 / 8.21s	3.82s
Qwen3 4B Instruct	3.30 / 5.47s	1.73s	54.8%	0%	31.43 / 39.30s	12.83s
Qwen3.5 4B	6.37 / 7.56s	3.97s	100%	0%	41.02 / 51.08s	18.87s
A.X 4.0 Light	4.26 / 6.41s	2.08s	83.3%	2.4%	35.08 / 38.43s	14.86s
Mi:dm 2.0 Mini	1.90 / 3.08s *	—	14.3%	0%	17.24 / 20.80s	실패

* 전부 DONT_KNOW 로 분류해 질문 스트리밍을 생략한 값이라 실제 속도로 볼 수 없다. Gemma 4 31B 는 한 호출이 192초 걸린 이상치가 있었다(게이트웨이 경유).

동시성·콜드스타트 (로컬 + 기준)

모델	코칭 15건×동시 5 총시간	호출당 p90	fan-out 중 타 사용자 꼬리질문	언로드 후 첫 꼬리질문	그다음 호출
Gemini 3.5 Flash-Lite	10.8s (15/15)	4.6s	2.1s	—	—
Mi:dm 2.0 Mini	99.2s (0/15)	—	33.1s	7.7s	1.2s
Qwen3 4B Instruct	224.1s (15/15)	81.1s	78.8s	10.7s	2.7s
A.X 4.0 Light	231.4s (15/15)	84.0s	81.2s	12.2s	2.7s
Qwen3.5 4B	304.7s (15/15)	110.8s	111.5s	15.5s	6.6s

5.6 GPU 적재 상태

모델	메모리 (num_ctx 8192)	적재
Qwen3 4B Instruct	4.2GB	100% GPU
Kanana-2-3B	3.4GB	100% GPU
Mi:dm 2.0 Mini	3.6GB	100% GPU
A.X 4.0 Light 7B	5.3GB	6% CPU / 94% GPU
Qwen3.5 4B (비전 포함)	6.4GB	29% CPU / 71% GPU
(1차) Qwen2.5 7B	5.6GB	8% CPU / 92% GPU
(1차) EXAONE 3.5 7.8B	6.3GB	19% CPU / 81% GPU

모델별 실행 전후 적재 상태는 `gpu-placement.log` 에 기록했다. 본 실험(하네스) 구간의 모든 측정은 위 적재 상태에서 이뤄졌다.

6. 실험 중 발견한 사항

6.1 GPU 간헐 인식 실패 → 무경고 CPU 풀백

- Ollama 로그에 `ggml_cuda_init: failed to initialize CUDA: initialization error` 가 기록되며 **0/33 레이어만 GPU 에 올라가고 오류 없이 CPU 로 실행됐다** (qwen3:4b 계열 약 10배 느려짐).
- 호스트 `nvidia-smi` 는 정상, 컨테이너 내 `/dev/nvidia*` 도 정상이었다. 수 분 뒤 재시도하면 다시 100% GPU 로 올라갔다.
- 발생 시각: 06:52Z, 07:32~07:34Z. 각각 배포(PR #233 06:48Z, PR #234 07:22Z) 후 4분·10분 안. **인과는 확정하지 못했다.**
- 영향: 같은 Ollama 를 쓰는 `devlog-devtalk-mcp` 도 동일하게 느려질 수 있다. 운영에 로컬 LLM 을 쓰면 `ollama ps` 의 PROCESSOR 감시가 필수다.

6.2 기본 문맥 길이 4096 에서 조용한 절단

- 긴 문맥 케이스의 Qwen 토큰라이저 기준 프롬프트가 **정확히 4,096 토큰으로 보고됐다** = 뒷부분이 잘렸다. 오류는 없다.

- 다른 케이스(2,956~3,227 토큰)도 출력까지 합치면 4096 에 근접한다.
- OpenAI 호환 엔드포인트로는 `num_ctx` 를 넘길 수 없어 **PARAMETER num_ctx 8192** 파생 모델을 만들어 해결했다 (또는 서버 전역 `OLLAMA_CONTEXT_LENGTH`).

6.3 thinking 제어

모델	think: false	reasoning_effort: "none"	비고
qwen3:4b (하이브리드)	무시됨 (reasoning 에 사고 출력)	사고 내용이 content 로 새어 나옴	사용 불가 → <code>qwen3:4b-instruct</code> 사용
qwen3.5:4b	—	정상 (reasoning 0)	기본값은 thinking on: 300토큰을 사고에 쓰고 content 빈 값 (이 측정은 CPU 풀백 상태에서 88초)
gpt-oss-120b	—	끝 수 없음	운영 <code>LLM_FLASH_MAX_TOKENS=512</code> 에서 추론이 토큰을 다 써 꼬리질문이 빈 문자열. 2048 에서 정상

6.4 서빙 호환성

- **Kanana-2-3B GGUF**: GPU 에 정상 적재됐지만 출력이 "관 관 관...", "n n n..." 로 깨졌다. Ollama 0.20.7 의 아키텍처 지원 문제로 추정. 벤치마크 점수는 좋지만 현 서빙 환경에서 사용 불가.
- **Gemma 4 E2B**: pull 시 Ollama 업그레이드를 요구. 공유 컨테이너라 업그레이드하지 않았다.

6.5 1차 예비 측정 (하네스 이전, 케이스 1개)

모델	꼬리질문	질문 풀 3개	비고
Gemini 3.5 Flash-Lite	2.5s	3.2s	
Gemini 3.1 Pro	—	22s	
qwen3:4b-instruct (8K)	2.0s	19s	같은 저가치 질문(결제 키 형식·길이) 반복
qwen2.5:7b (8K)	4.4s	34s	
exaone3.5:7.8b (8K)	14.5s	39s	복합 질문, 비상업 라이선스

예비 측정은 케이스가 1개라 결론에 쓰지 않았고, 본 실험 설계의 근거로만 썼다.

7. 비용 추정 (게이트웨이를 못 쓸 경우)

세션 1회 모델: 질문 풀 1 + 답변 10(꼬리질문 10) + 피드백(패널 3·종합 1·자기소개 1·코칭 10). 토큰은 운영 로그 평균 — Flash 입력 37.9k / 출력 7.5k, Pro 입력 9.8k / 출력 1.6k. 정가 기준. Pro 의 thinking 토큰은 로그에 없어 **현재 구성 비용은 과소추정**이다.

옵션	가격 (입력/출력, per 1M)	세션당	1천 세션	월 300세션
현재 구성 Gemini 3.5 Flash-Lite + 3.1 Pro	\$0.30/\$2.50 + \$2.00/\$12.00	\$0.069	\$69.0	\$20.7
Gemini 3.5 Flash-Lite 단독	\$0.30/\$2.50	\$0.037	\$37.0	\$11.1
Solar Pro 4	\$0.30/\$1.20	\$0.025	\$25.2	\$7.6
DeepSeek V4.1 Flash (OpenRouter)	\$0.30/\$1.20	\$0.025	\$25.2	\$7.6
gpt-oss-120b (Groq)	\$0.15/\$0.60	\$0.013	\$12.6	\$3.8
Qwen3.8-Flash (Alibaba)	\$0.15/\$0.47	\$0.011	\$11.4	\$3.4
gpt-oss-120b (DeepInfra)	\$0.037/\$0.17	\$0.003	\$3.3	\$1.0
Kimi K2.6 (Moonshot)	\$0.95/\$4.00	\$0.082	\$81.6	\$24.5

옵션	가격 (입력/출력, per 1M)	세션당	1천 세션	월 300세션
Kimi K3 (Moonshot)	\$3.00/\$15.00	\$0.279	\$279.3	\$83.8
로컬 (ana-server)	전기료	≈ \$0	≈ \$0	≈ \$0 — 단, \$5 품질·동시성 한계

가격 출처는 OpenRouter models API·각 제공사 가격 페이지 (2026-09-17 조회). Gemma 4 31B 의 외부 제공자 가격은 조사하지 않았다.

8. 종합 평가

모델	품질	형식·채점	속도	동시성	라이선스/경로	판정
Gemini 3.5 Flash-Lite + 3.1 Pro	◎	◎	◎	◎	게이트웨이 (학교 키)	운영 유지
Gemma 4 31B	◎	◎	△ (꼬리질문 9s, p90 54s)	미측정	오픈 가중치	Pro 티어 Plan B
Solar Pro 4	○ (정상 답변 ◎, 모름·재설명 △)	○	○ (2.3s)	미측정	비공개 가중치 API	Flash 티어 Plan B (프롬프트 보정 전제)
gpt-oss-120b	△	○ (토큰 상향 시)	△ (4.3s)	미측정	오픈 가중치, 최저가	비용 우선 시 후보
Llama 4 Maverick	△	○	◎ (1.9s)	미측정	오픈 가중치	비권장 (깊이 부족)
Qwen3 4B Instruct	×	△	○	×	로컬	비권장
Qwen3.5 4B	×	×	△	×	로컬	비권장
A.X 4.0 Light	×	△	△	×	로컬	비권장
Mi:dm 2.0 Mini	×	×	—	×	로컬	사용 불가
Kanana-2-3B	—	×	—	—	로컬	현 Ollama 에서 사용 불가
Kimi K2.6 / K3	미측정	미측정	미측정	—	로컬 불가, API 고가	우선순위 낮음
Qwen3.8-Flash, DeepSeek V4.1 Flash	미측정	미측정	미측정	—	API 저가	키 확보 시 측정 권장

(◎ 우수 · ○ 양호 · △ 조건부 · × 부적합)

로컬 LLM 이 이 서버에서 운영 대체가 안 되는 이유

- 품질:** 로컬 최고가 Claude 판정 2.7 (Gemini 4.0). 모름·재설명·확인형 단답 대응이 특히 약하다.
- 동시성:** GPU 1장 직렬 처리 → 한 사용자의 피드백 생성 중 다른 사용자의 꼬리질문 79~111초.
- 채점 신뢰도:** 사실대조 규칙 55~70%, 점수 라벨 9~82%. 리포트 점수가 흔들린다.
- 운영 리스크:** 무경고 CPU 풀백, 기본 문맥 절단, 모델 언로드 후 콜드스타트(7.7~15.5초, Flash 타임아웃 10초 초과), 공유 GPU 경합.

로컬을 계속 검토하려면 31B급 모델을 올릴 수 있는 VRAM 24GB 이상 GPU 와 배치 서빙(vLLM 등)이 필요하다.

9. 권고 및 후속 작업

- 운영 유지:** 현재 게이트웨이 Gemini 구성 그대로.
- 게이트웨이 지속성 확인:** 학교 키의 유효 기간·사용 한도 확인 (Plan B 시급성 결정).
- Plan B 사전 검증:** PR #234 의 티어 오버라이드로 스테이징에서

- Pro → `google/gemma-4-31B-it` (피드백·질문 풀 지연 허용 범위 확인)
- Flash → `solar-pro4` + 프롬프트 보정(질문 80자 제한 강화, 기대 신호 누설 금지, 재설명 규칙 강화) 후 하네스 재측정

4. 외부 API 키 확보 시 Qwen3.8-Flash-DeepSeek V4.1 Flash·Kimi K2.6 을 같은 하네스로 측정.

5. 공유 Ollama GPU 풀백 원인 조사 (다른 프로젝트 영향): 배포 시점과의 인과 확인.

6. 운영 코드 개선 후보(이번 실험에서 드러남):

- `AnswerEvaluation.specificity/logic` 이 `float` 필수라 확인형 단답에서 프롬프트가 지시한 null 을 주면 평가 전체가 버려진다 → Optional 검토.
- 질문 풀 JSON 파싱 실패 시 재시도 없음(Gemini Flash-Lite 도 긴 문맥에서 1/2 실패) → 질문 풀 체인에 `with_retry` 검토.

10. 한계

- 케이스는 합성 22개. 통계적 유의성보다 **뚜렷한 격차** 확인용이다. 상위권(Gemini·Gemma·Solar) 간 0.1~0.3점 차는 오차 범위로 본다.
- LLM 판정은 사람 평가를 대체하지 않는다. 판정자 계열 편향이 확인됐다(\$5.1).
- 게이트웨이 모델 지연에는 게이트웨이 오버헤드가 포함되어, 같은 모델을 다른 제공자로 쓰면 다를 수 있다.
- 게이트웨이 모델의 동시성(fan-out)은 Gemini Flash-Lite 만 측정했다.
- 스트리밍 호출의 토큰 사용량 집계는 청크 중복 합산으로 부정확해 분석에서 제외했다.
- 로컬 결과는 GTX 1660 Ti · Ollama 0.20.7 · Q4 양자화 기준이다.

11. 실험 진행 기록

시각은 git·PR 메타데이터, Ollama 로그, API 응답 타임스탬프, `gpu-placement.log` 로 확인한 값만 적었다.

시각 (KST)	내용	근거
15:48	PR #233 머지 → 배포 시작	PR 메타데이터
15:50	예비 측정 첫 로컬 호출 (qwen2.5:3b 응답 확인)	API 응답 created
15:52	첫 CUDA 초기화 실패 → CPU 풀백	Ollama 로그 06:52Z
15:54	배포가 AI 컨테이너를 재생성 → 진행 중이던 첫 벤치 실행 실패, 재실행	컨테이너 created
16:09	예비 측정 결과로 PR #234(티어별 엔드포인트) 작성	git 커밋
16:22	PR #234 머지·배포 (기본값 빈 값, 동작 변화 없음)	PR 메타데이터
16:31	판정 모델(claude-opus-5) 게이트웨이 응답 확인 — 이 무렵 게이트웨이 6개 모델 실행 중	API 응답 created
16:32~16:34	CUDA 초기화 실패 재발 → 재시도로 복구 확인, 모델별 GPU 적재 확인 로직 추가	Ollama 로그 07:32Z, 07:34Z
16:43	로컬 본 실험 시작 (Qwen3 4B Instruct, 100% GPU)	gpu-placement.log
16:57	Qwen3.5 4B 시작 (29% CPU)	gpu-placement.log
17:22	Kanana-2-3B 시작 → 출력 깨짐 확인	gpu-placement.log
18:00	Kanana-2-3B 실행 중단, Mi:dm 2.0 Mini 시작	gpu-placement.log
18:07	Gemma 4 E2B 파생 모델 생성 실패(Ollama 업그레이드 필요), A.X 4.0 Light 시작	gpu-placement.log
18:23	로컬 실행 완료	gpu-placement.log
18:23~18:35	자동 지표 집계, 확인형 단답 태그 준수 지표 보정, gpt-oss-120b max_tokens 2048 재측정, 블라인드 판정 44건	보고서 커밋 이전
18:35	결정용 보고서·하네스 커밋 (PR #235, 18:47 머지)	git 커밋

12. 재현 방법

stackup-ai 컨테이너에 `ai/scripts/llm_eval/` 을 복사한 뒤 컨테이너 안에서 실행한다.

```
# 1) 로컬 모델은 8K 파생 모델 생성 (호스트)
printf "FROM qwen3:4b-instruct\nPARAMETER num_ctx 8192\n" \
| docker exec -i ollama sh -c "cat > /tmp/Mf && ollama create stackup-eval-qwen3-4b-instruct-8k -f /tmp/Mf"

# 2) 실행 (컨테이너 안, 작업 디렉터리 llm_eval)
python run_eval.py --label gw-gemini-3.5-flash-lite --model gemini-3.5-flash-lite \
--reps 3 --latency --out /tmp/eval/gw-gemini-3.5-flash-lite.jsonl
python run_eval.py --label local-qwen3-4b-instruct --model stackup-eval-qwen3-4b-instruct-8k \
--base-url http://ollama:11434/v1 --api-key ollama --reps 3 --latency \
--out /tmp/eval/local-qwen3-4b-instruct.jsonl
python run_eval.py --label local-qwen3.5-4b --model stackup-eval-qwen3.5-4b-8k \
--base-url http://ollama:11434/v1 --api-key ollama --reps 3 --latency \
--extra-body '{"reasoning_effort": "none"}' --out /tmp/eval/local-qwen3.5-4b.jsonl
python run_eval.py --label gw-gpt-oss-120b-mt2048 --model accounts/fireworks/models/gpt-oss-120b \
--suites followup --reps 3 --flash-max-tokens 2048 --out /tmp/eval/gw-gpt-oss-120b-mt2048.jsonl

# 3) 분석·판정
python analyze.py /tmp/eval/*.jsonl > auto-metrics-summary.json
python judge.py --exclude local-kanana2-3b --out eval-judge.jsonl /tmp/eval/*.jsonl > eval-judge-table.json
```

부록 A. 출력 예시

A.1 사실 불일치 답변 (f-infra-fact-error)

지원자: "HPA 는 메모리 50% 를 기준으로 잡았습니다... 피크 대응은 따로 한 건 없고..." (이력서: CPU 70%, CronJob 사전 스케일아웃)

모델	꼬리질문
Gemini Flash-Lite	이력서에는 CPU 70%와 사전 스케일아웃 CronJob을 운영하셨다고 되어 있는데, 답변에서 메모리 50%와 HPA 단독 대응이라고 하신 이유는 무엇인가요?
Gemma 4 31B	이력서에는 CPU 70% 기준과 CronJob을 통한 사전 스케일아웃을 운영하셨다고 적혀 있는데, 답변하신 내용과 차이가 있는 이유가 무엇인가요?
Solar Pro 4	이력서에 적힌 CPU 70% 기준과 월급날 피크 대비 CronJob 사전 스케일아웃은 어떤 근거로 선택하셨고, 그 사전 스케일아웃이 없었다면 피크 때 어떤 문제가 생겼을 거라고 보시나요?
Llama 4 Maverick	서비스 특성상 메모리를 많이 쓴다고 했는데, 어떤 부분에서 메모리를 많이 사용하나요? (불일치 농침)
Qwen3 4B (로컬)	메모리 50% 기준을 선택한 이유가 무엇인가요? CPU 70% 기준이 더 일반적이지 않나요? (유도형)
A.X 4.0 Light (로컬)	HPA 기준 설정에 대해 구체적으로 설명해 주세요. 메모리 50%를 선택하신 이유가 무엇인지, 그리고 사전 스케일아웃을 CronJob으로 운영한 이유도 함께 말씀해 주시겠어요? (답변과 모순되는 전제)

A.2 좋은 답변 (f-strong-backend) — 약한 축 파고들기

모델	꼬리질문
Gemini Flash-Lite	Outbox 테이블을 폴링하는 릴레이에서 발행 실패가 발생하면 데이터 정합성을 어떻게 보장하시나요?

모델	꼬리질문
Gemma 4 31B	Outbox 테이블의 데이터를 릴레이가 풀링해 발행할 때, 메시지가 중복 발행될 가능성은 어떻게 해결하셨나요?
Solar Pro 4	Outbox 릴레이가 풀링 중 실패하거나 중복 발행했을 때, 멍등 키만으로는 막을 수 없는 케이스가 생기는데 그 경계는 어떻게 처리하셨나요?
Qwen3 4B (로컬)	결제 키에 유니크 제약을 걸어 두 번째 요청을 돌려주는 부분에서, 그 키의 구체적인 형식은 무엇이었나요? (저가치)
Qwen3.5 4B (로컬)	동일한 트랜잭션 내에서 outbox 테이블에 주문 정보를 기록하신 구체적 SQL 또는 애플리케이션 로직은 무엇인가요?

A.3 "모르겠습니다" (f-dont-know-explicit)

모델	의도	후속 문장
Gemini Flash-Lite	DONT_KNOW	그럼 PostgreSQL의 VACUUM이 어떤 역할을 하는지 알고 계신 범위에서 간략히 말씀해 주시겠어요?
Gemma 4 31B	DONT_KNOW	괜찮습니다. 그럼 MVCC의 기본 개념이나... 아는 범위 내에서 설명해 주시겠어요?
Solar Pro 4	DONT_KNOW	...xmin horizon 과 dead tuple 회수 지연, 그리고 테이블 bloat 으로 이어지는 흐름을 다시 설명해 드릴까요? (정답 누설)
Qwen3 4B (로컬)	DONT_KNOW	...영향에 대해 잘 모르시는 이유가 무엇인가요? (부적절)

A.4 재설명 요청 (f-clarification)

모델	의도	재설명
Gemini Flash-Lite	CLARIFICATION	CPU 사용량이 갑자기 높을 때 자동으로 늘려주는 HPA의 기준을 70%로 정한 이유와, 트래픽이 몰리기 전에 미리 서버를 늘려둔 이유를 각각 쉽게 설명해 주시겠어요?
Solar Pro 4	CLARIFICATION	HPA 가 CPU 70% 에 반응하기까지 메트릭 수집·파드 기동 시간이 걸리는데... (기대 신호를 그대로 노출)
Qwen3 4B (로컬)	CLARIFICATION	HPA 기준을 CPU 70%로 설정하신 이유와..., 좀 더 쉽게 설명해 주실 수 있나요? (원 질문 반복)
Mi:dm 2.0 Mini (로컬)	DONT_KNOW	(오분류 — 운영에서 폐기됨)

A.5 코칭 리라이트 (c-weak-backend)

원 답변: "그냥 중복이 안 생기게 잘 처리했고요, 트랜잭션도 잘 관리해서 문제없이 해결됐습니다."

- **Solar Pro 4** — 한 줄 코칭: "두 기법이 각각 어떤 실패 케이스를 막는지 구체적으로 구분해서 말하면, 멍등성과 트랜잭션 경계에 대한 이해를 훨씬 설득력 있게 전달할 수 있습니다."
- **Qwen3 4B (로컬)** — 판정자 지적: "지원자의 실제 답변을 전혀 반영하지 않고 모범 답안으로 완전히 대체함", "모범 답안과 재작성 답안이 거의 동일".