

로컬 LLM 전환 심층 조사 — 리서치 및 실험 리포트

항목	내용
실험일	2026-09-17 (19:00~22:30 KST)
목적	1차 비교 실험의 "로컬 LLM 비권장" 결론이 설정·서빙 스택·모델 선택의 한계 였는지, 하드웨어 자체의 한계 였는지 가려내고, 로컬로 가려면 무엇이 필요한지 정리
선행 문서	../llm-provider-evaluation-2026-09.md (결정용 요약), ../llm-eval-2026-09/experiment-report.md (1차 실험 리포트)
실험 도구	ai/scripts/llm_eval/ — 이번에 load_test.py (동시 사용자 부하), run_eval.py --constrain-json (JSON 스키마 강제) 추가
원시 데이터	data/ — 모델별 원시 출력, 자동 지표, 블라인드 판정, GPU 원격 측정 5,260건, 적재 로그

0. 결론

- 현재 서버(GTX 1660 Ti 6GB)로 Gemini 를 대체하는 것은 불가능하다. 원인은 설정이 아니라 하드웨어다.** 프롬프트 처리 속도가 어떤 설정·서빙 스택에서도 **초당 약 240토큰**에 묶였다. 병렬 슬롯을 켜도 동시 4명 기준 처리량은 18.4 → 21.4 요청/분(+16%)에 그쳤고, 부하 구간의 39%가 80W 전력 상한에 걸렸다.
- 로컬 품질은 모델 크기에 따라 갈린다.** 이 서버 GPU 에 올라가는 4B급 이하 모델은 블라인드 품질(Claude 판정) 꼬리질문 최고 3.0점, 코칭 최고 3.0점으로 Gemini Flash-Lite(4.1점, 4.0점)에 못 미친다. 반면 **Gemma 4 26B-A4B 는 3비트로 깎은 상태에서도** 꼬리질문 3.7, 질문 풀 4.2, 코칭 4.3점으로 Gemini 에 근접하거나 같았다.
- 따라서 "로컬 LLM" 은 GPU 를 바꾸는 결정이다.** 24~32GB GPU(중고 RTX 3090 ~₩1.0~1.35M, RTX 5090 ~₩5.5M)에서 Gemma 4 26B-A4B 를 4비트 이상으로 돌리는 구성이 품질·속도 모두 현실적인 후보다. 다만 현재 사용량(누적 세션 95건)에서는 **비용상 이득이 없고**(자체 서버가 싸지는 지점: 월 약 2,400~5,500 세션), 게이트웨이는 무료다.
- 당장 할 수 있는 것:** (a) 구매 전 GPU 를 몇 시간 임대해 같은 하네스로 Gemma 4 26B-A4B 를 실측, (b) 공유 Ollama 의 **GPU 풀림(무경고 CPU 풀백) 대책** 적용, (c) 게이트웨이 장애 대비 풀백이 필요하면 현 서버에 Gemma 4 E2B 를 전용 llama.cpp 컨테이너로 두되 **동시 1~2명까지만** 쓰는 제한적 모드로.

1. 1차 실험의 결론을 흔들 수 있었던 변수

1차 실험 조건	의심	이번에 검증한 방법
Ollama 0.20.7 기본값 (요청 직렬 처리)	병렬 설정이면 동시성이 살아날 수 있다	llama.cpp 최신 서버로 1슬롯 vs 4슬롯, 동시 1/2/4/8명 부하
5개월 전 Ollama	최신 서빙이면 깨졌던 모델(Kanana-2, Gemma 4)이 동작할 수 있다	최신 llama.cpp 로 Kanana-2-3B-Mi:dm·Gemma 4 E2B/E4B 재평가
6GB 에 들어가는 소형 모델만 평가	더 큰 모델은 품질이 충분할 수 있다	MoE 모델을 GPU+CPU 로 나눠 실행해 품질 하한선 측정 (Gemma 4 26B-A4B, Qwen3.6-35B-A3B, gpt-oss-20b, Kanana-2-30B)
형식 오류(JSON 파싱 실패)	출력 형식을 강제하면 해결될 수 있다	JSON 스키마 강제 디코딩
느린 응답	설정 문제일 수 있다	플래시 어텐션·배치 크기·KV 캐시 양자화별 속도 측정, Ollama 와 비교
GPU 간헐 풀림	원인 불명	리서치 + 재발 시각 기록

2. 리서치 요약

2.1 서빙·최적화

- **Ollama 최신은 v0.34.1(2026-09-14)**. 서버의 0.20.7 은 5개월 전 버전이다. v0.30 부터 내부 엔진이 llama.cpp llama-server 로 바뀌었고 OLLAMA_NUM_PARALLEL 을 켜면 요청을 한 번의 연산으로 묶어 처리한다. 기본값 1 은 완전 직렬이다.
- **llama.cpp 병렬 슬롯**: `-np N` (슬롯 수), 연속 배치 기본 켜짐, `-c` 는 전체 문맥을 슬롯 수로 나눈다. KV 캐시 `q8_0` 양자화로 메모리 절반. 동급 이상 GPU(RTX 3060) 공개 벤치마크에서 3.8B 모델 생성 처리량이 1→8 병렬에서 108→276 tok/s 로 늘었다.
- **최소 지원 버전**: Kanana-2 는 2026-02 이후 llama.cpp, Gemma 4 `-qat` 태그는 Ollama 0.30.6 이상, Qwen3.5 는 0.17.4 이상.
- **MoE CPU 오프로드**: `--n-cpu-moe N` 으로 전문가(expert) 가중치만 CPU 에 두고 어텐션은 GPU 에 둔다. 6GB + RAM ~11GB 에서는 파일 크기 12GB 이하(2~3비트)만 현실적이며, 생성 8~18 tok/s·프롬프트 300~800 tok/s 로 추정됐다.
- **JSON 스키마 강제**: llama.cpp `response_format.json_schema` ·GBNF 지원. `$ref` 포함 스키마는 조용히 무시되는 알려진 이슈가 있어 서버 측 검증이 여전히 필요하다.

2.2 GPU 끊김 원인

- **알려진 NVIDIA Container Toolkit 문제**: runc + systemd cgroup 드라이버 환경에서 `systemctl daemon-reload` 가 일어나면 실행 중인 컨테이너의 GPU 장치 접근이 사라진다. 증상은 `failed to initialize CUDA` 또는 NVML 오류이며 Ollama 는 **오류 없이 CPU 로 폴백**한다. 서버 설정(toolkit 1.19.0, runc)이 해당 조건이다.
- `docker compose up --build` 자체가 daemon-reload 를 부르는지는 확인되지 않았다(미확정). 패키지 설치·자동 업데이트도 흔한 트리거다.
- **대책**(모두 sudo 필요): cgroupfs 드라이버 전환, compose 에 `/dev/nvidia*` 장치 명시, `nvidia-ctk system create-dev-char-symlinks`, CDI 모드. **감지**: `nvidia-smi -L` 헬스체크, Ollama `/api/ps` 의 `size_vram < size` 경보, 컨테이너 재시작으로 복구.

2.3 하드웨어·호스팅·비용

한국어가 강한 중형 오픈 모델 (상업 사용 가능 여부 포함)

모델	총/활성 파라미터	라이선스	한국어 근거	4비트 가중치
Gemma 4 31B	31B / 31B	Apache-2.0	1차 블라인드 실험에서 Gemini 동급	17.5~20.5GB
Gemma 4 26B-A4B	26B / 3.8B	Apache-2.0	이번 실험 3비트에서도 Gemini 근접	14.4~17.2GB
Qwen3.6-35B-A3B	35B / 3B	Apache-2.0	공개 한국어 점수 없음	~20~22GB
Kanana-2-30B-A3B	30B / 3B	Kanana License (월 사용자 1천만 미만 자사 서비스 허용, "Powered by Kanana" 표기)	KMMLU 68.3, KoMT-Bench 8.21	~17~19GB
HyperCLOVA X SEED Think 32B	32B	월 사용자 1천만 미만 상업 허용(네이버 경쟁 서비스 불가)	KMMLU 71.3	~20GB
EXAONE 4.0/4.5 32~33B	32~33B	비상업	KMMLU 75.2	~20GB
gpt-oss-20b	21B / 3.6B	Apache-2.0	Korean MMMLU 77.6	~13GB

GPU 와 기대 성능 (공개 벤치마크, 엔진·양자화가 서로 달라 참고용)

GPU	가격 (2026-09)	30B MoE (3~4B 활성)	31~32B dense
RTX 3090 24GB 중고	₩0.95~1.35M (미확정)	Gemma 4 26B-A4B Q4: 64~128 tok/s	Gemma 4 31B Q4: 30~34 tok/s

GPU	가격 (2026-09)	30B MoE (3~4B 활성)	31~32B dense
RTX 5090 32GB	₩5.5M(현금)/₩6.5M(카드)	Qwen3-30B-A3B: 1명 TTFT 0.17s~192 tok/s, 4명 TTFT 0.75s	~50~60 tok/s (추정)
RTX PRO 6000 96GB	\$13,250~16,000	30B MoE 고동시성에서 5090 4장보다 빠름	Gemma 4 31B NVFP4: 1명 TTFT 0.11s, 4명 ~1s
클라우드 임대	RunPod 3090 \$0.22~0.50/h, 4090 \$0.34~0.74/h, 5090 \$0.69~0.99/h	—	—

서버리스(사용 시에만 과금)는 콜드스타트 60~120초(스냅샷 사용 시 7~15초)로 꼬리질문 1~2초 목표와 맞지 않는다.

월 비용 비교 (세션당 입력 48k·출력 9k 토큰, 자체 서버는 36개월 감가 + 전기료, 인건비 제외)

월 세션	300	3,000	30,000
Gemini Flash-Lite 유료	\$11	\$111	\$1,107
Gemini Flash-Lite + Pro 혼합 유료	\$36	\$360	\$3,600
Qwen3.8-Flash API	\$3	\$32	\$315
gpt-oss-120b API (DeepInfra)	\$2	\$19	\$194
중고 3090 서버 구매	\$90	\$90	용량 부족
5090 서버 구매	\$205	\$205	\$410~560 (2장 또는 PRO 6000)
5090 상시 임대 (RunPod)	\$504	\$504	\$1,000~1,500
학교 게이트웨이 (현재)	\$0	\$0	\$0

- 자체 서버가 Gemini Flash-Lite 유료보다 싸지는 지점: 중고 3090 월 ~2,400 세션, 5090 월 ~5,500 세션. Pro 혼합 대비 ~1,700 세션.
- 저가 오픈 모델 API 대비로는 월 ~8,600~32,000 세션이 되어야 자체 서버가 싸다.

정부·대학 GPU 지원: NIPA 고성능 컴퓨팅 지원(GPU 트랙은 중소기업만, 2026년 모집 마감), KISTI 국가슈퍼컴퓨터 6호기(2026-09-28~10-16 신청, 연구용), NIPA 첨단 GPU(학습용 대규모). 모두 기간 한정 연구·개발용이라 **상시 운영 서비스용으로는 맞지 않는다.**

3. 실험 설계

3.1 환경

항목	값
GPU	GTX 1660 Ti 6GB (노트북용, 80W 전력 상한, Turing)
서빙	<code>ghcr.io/ggml-org/llama.cpp:server-cuda</code> (2026-09-17 빌드). 공유 Ollama 는 건드리지 않고 별도 테스트 컨테이너 (메모리 상한 6~11GB)로 실행
모델 파일	Ollama 저장소 GGUF 재사용 + Hugging Face 에서 unsloth:ggml-org GGUF 다운로드
원격 측정	<code>nvidia-smi</code> 2초 간격 5,260건 (온도·전력·사용률·스토를 원인)

3.2 실험 목록

ID	실험	측정
X0	동시성 기준선: Gemini 게이트웨이	동시 1/2/4/8명 꼬리질문 각 16건 + 코칭 15건×동시 5 도중 꼬리질문 6건

ID	실험	측정
X1	llama.cpp Qwen3 4B, 1슬롯 vs 4슬롯(KV q8)	X0 과 동일
X1b	프롬프트 처리·생성 속도 분리 측정	2.5k 토큰 프롬프트, 플래시 어텐션 on/off, 배치 크기, KV f16/q8, Ollama 비교
X2	최신 서빙 재평가: JSON 스키마 강제(Qwen3 4B), Kanana-2-3B, Mi:dm 2.0 Mini, Gemma 4 E2B/E4B	1차 실험과 같은 케이스·자동 지표 (꼬리질문·코칭 2회, 질문 풀 2회)
X3	MoE CPU 오프로드 품질 하한선: Gemma 4 26B-A4B(IQ3_S), Qwen3.6-35B-A3B(Q2_K_XL), gpt-oss-20b(MXFP4), Kanana-2-30B(Q2_K 재양자화)	같은 케이스 1회 + 속도
X4	Gemma 4 E2B/E4B 동시성	X0 과 동일
J	블라인드 판정	새 모델 7종 + 기존 4종(Gemini Flash-Lite, Gemini Pro, Gemma 4 31B, 1차 Qwen3 4B)을 한 프롬프트에 익명 섞어 Gemini 3.1 Pro-Claude Opus 5 가 채점, 44건

무효 처리한 측정:

- 공유 Ollama 기본값 부하 기준선: 실행 도중 GPU 끊김으로 **CPU 에서 돌아 무효**(data/raw/*-INVALID-cpu-fallback.jsonl).
- Kanana-2-30B: Q4 파일을 2비트로 재양자화한 결과 **의미 없는 문자열 반복**으로 품질 측정 불가, 중단(*-INVALID-broken-requant.jsonl).

4. 결과

4.1 GPU 처리 한계 — 설정으로는 안 바뀐다

2.5k 토큰 한국어 프롬프트, Qwen3 4B Q4_K_M, 슬롯 1개.

설정	프롬프트 처리 (tok/s)	생성 (tok/s)
llama.cpp, 플래시 어텐션 on	246 / 238	60 / 59
llama.cpp, 플래시 어텐션 off	226 / 218	23 / 44
llama.cpp, 마이크로배치 1024	245 / 246	59 / 60
llama.cpp, 마이크로배치 256	241 / 235	59 / 60
Ollama 0.20.7 (공유)	239	55

- 모든 설정에서 프롬프트 처리가 ~240 tok/s** 로 같았다. 운영 꼬리질문 입력 중 캐시되지 않는 고유 부분(답변·대화 이력·검색 문맥, 추정 700~1,500 토큰)만으로 3~6초, 질문 풀(3~5k 토큰)은 12~20초가 프롬프트 읽기에 든다.
- 병렬 처리 시 요청당 프롬프트 처리는 150 tok/s 안팎으로 떨어지고, 생성은 4병렬에서 요청당 8~27 tok/s 로 나뉜다. **총 처리량은 1병렬 19.6 → 4병렬 22.6 tok/s(프롬프트 포함)** 로 거의 늘지 않았다.
- 원격 측정: 부하 구간(40W 이상) 2,324건 중 **907건(39%)**이 **80W 소프트웨어 전력 상한**에 걸렸다. 최고 75°C, 온도 스로틀은 없었다.

4.2 동시성

꼬리질문 총지연 중간값 (동시 사용자 수별, 각 16건)

동시 요청	Gemini Flash-Lite (게이트웨이)	Gemma 4 E2B (4슬롯)	Gemma 4 E4B (4슬롯)	Qwen3 4B (4슬롯)	Qwen3 4B (1슬롯)
1	1.71s	1.60s	2.83s	3.08s	2.96s

동시 요청	Gemini Flash-Lite (게이트웨이)	Gemma 4 E2B (4슬롯)	Gemma 4 E4B (4슬롯)	Qwen3 4B (4슬롯)	Qwen3 4B (1슬롯)
2	1.70s	3.37s	6.22s	6.67s	5.80s
4	1.75s	5.43s	10.90s	11.59s	13.16s
8	1.75s	10.02s	18.04s	23.77s	26.38s
처리량 (요청/분, 동시 8)	252.0	47.0	24.5	18.1	18.6
10초 초과 (동시 8, 16건 중)	0	8	13	16	13

첫 질문 토큰까지(TTFT) 중간값

동시 요청	Gemini	Gemma 4 E2B	Gemma 4 E4B	Qwen3 4B 4슬롯	Qwen3 4B 1슬롯
1	1.34s	0.89s	1.64s	1.62s	1.59s
4	1.35s	1.63s	3.40s	3.75s	11.94s
8	1.31s	7.25s	13.97s	15.89s	25.45s

피드백 생성(코칭 15건×동시 5) 도중 다른 사용자의 꼬리질문 6건

서빙	코칭 15건 총시간	꼬리질문 지연 중간값	최대
Gemini Flash-Lite	10.6s	1.55s	1.71s
Gemma 4 E2B (4슬롯)	65.1s	23.9s	26.2s
Qwen3 4B (4슬롯)	113.3s	45.9s	51.5s
Gemma 4 E4B (4슬롯)	117.3s	46.8s	50.2s
Qwen3 4B (1슬롯)	205.3s	69.6s	72.9s

- 병렬 슬롯은 첫 토큰을 앞당기지만(4명 기준 **11.9s → 3.8s**) 총지연과 처리량은 거의 그대로다. GPU 연산이 병목이라 요청을 섞어도 나눠 먹을 뿐이다.
- 가장 가벼운 Gemma 4 E2B 도 한 사람이 피드백을 만드는 동안 다른 사람의 꼬리질문이 **24초** 걸린다.

4.3 블라인드 품질 (overall, 5점 만점)

판정자 간 ±1점 이내 일치 **93.1%**(204쌍), 평균 절대차 0.59. 1차 실험과 마찬가지로 Gemini 판정자가 Google 계열에 후했으므로 **Claude 점수를 기준으로 본다.**

모델	실행	꼬리질문 Claude / Gemini	질문 풀 Claude / Gemini	코칭 Claude / Gemini
Gemini 3.1 Pro (현 Pro)	게이트웨이	—	4.80 / 4.60	—
Gemini 3.5 Flash-Lite (현 Flash)	게이트웨이	4.07 / 4.43	4.20 / 4.00	4.00 / 4.33
Gemma 4 31B	게이트웨이	4.07 / 4.86	4.00 / 4.40	4.33 / 5.00
Gemma 4 26B-A4B (3비트 IQ3_S)	로컬, CPU 오프로드	3.71 / 3.86	4.20 / 3.60	4.33 / 4.00
Qwen3.6-35B-A3B (2비트 Q2_K_XL)	로컬, CPU 오프로드	3.14 / 3.00	3.75 / 4.25	3.00 / 3.33
gpt-oss-20b (MXFP4)	로컬, CPU 오프로드	3.21 / 2.86	2.75 / 2.75	코칭 전부 실패
Gemma 4 E4B (Q4)	로컬, GPU	3.00 / 2.79	3.20 / 3.80	3.00 / 3.33
Gemma 4 E2B (Q4)	로컬, GPU	2.86 / 2.50	2.80 / 2.60	2.67 / 3.67
Qwen3 4B Instruct (1차, Ollama)	로컬, GPU	2.36 / 2.43	2.80 / 2.80	2.00 / 3.00

모델	실행	포리질문 Claude / Gemini	질문 풀 Claude / Gemini	코칭 Claude / Gemini
Qwen3 4B + JSON 스키마 강제	로컬, GPU	—	2.40 / 2.40	2.00 / 2.67
Kanana-2-3B (Q4)	로컬, GPU	1.29 / 1.21	1.00 / 1.00	1.00 / 1.00

포리질문 세부 측 (Claude)

모델	relevance	depth	language
Gemini Flash-Lite	4.57	3.71	4.43
Gemma 4 31B	4.50	3.93	4.57
Gemma 4 26B-A4B (3비트)	4.14	3.57	4.43
Qwen3.6-35B-A3B (2비트)	3.36	3.00	4.07
gpt-oss-20b	3.50	2.86	4.21
Gemma 4 E4B	3.57	2.93	3.71
Gemma 4 E2B	3.21	2.64	3.79
Qwen3 4B	2.86	2.29	3.07
Kanana-2-3B	1.57	1.29	2.79

판정자가 지정한 대표 문제:

- **Gemma 4 E2B/E4B:** 재설명 요청에 원 질문을 표현만 바꿔 반복, 이미 답한 내용 재질문. 코칭 리라이트가 "모르겠다"고 한 지원자를 완벽히 아는 것처럼 꾸밈.
- **Gemma 4 26B-A4B:** 재설명을 두 갈래로 잘 풀었으나 문장이 길다는 지적 정도.
- **Qwen3 4B + JSON 강제:** 사실 오류("오래 열린 트랜잭션은 xmin 이 높은 상태를 유지"), 비문 증가.
- **Kanana-2-3B:** 직전 질문을 글자 그대로 반복, "~설명하세요" 명령조, 근거 인용 날조.

4.4 형식 준수·채점 신뢰도 (자동 지표)

모델	태그 준수	의도 분류	점수 라벨	사실대조 규칙	판별력 (백엔드/인성)	질문 풀 성공	근거 인용 실재	코칭 성공
Gemini Flash-Lite	100%	100%	100%	100%	3.0 / 2.0	90%	100%	100%
Gemma 4 31B (게이트웨이)	100%	100%	100%	100%	3.0 / 3.0	100%	100%	100%
Gemma 4 26B-A4B 3비트	100%	92.9%	100%	100%	5.0 / 3.0	100%	100%	100%
Qwen3.6-35B-A3B 2비트	100%	92.9%	90.9%	100%	3.0 / 3.0	80%	100%	100%
gpt-oss-20b	100%	100%	90.9%	100%	2.0 / 3.0	80%	100%	0%
Gemma 4 E4B	100%	96.4%	90.9%	100%	3.0 / 3.0	100%	100%	100%
Gemma 4 E2B	100%	92.9%	86.4%	90.9%	3.0 / 2.0	100%	100%	100%
Qwen3 4B (1차)	100%	100%	81.8%	57.6%	2.0 / 2.0	90%	100%	100%
Qwen3 4B + JSON 강제	—	—	—	—	—	100%	100%	100%
Kanana-2-3B	96.4%	78.6%	63.6%	18.2%	0.0 / 1.0	100%	5.6%	50%
Mi:dm 2.0 Mini	28.6%	14.3%	9.1%	72.7%	—	50%	88.0%	16.7%

- **gpt-oss-20b 코칭 실패 원인:** llama.cpp 가 `The model produced output that does not match the expected peg-native format` 500 오류를 냈다(3/3). 긴 문맥 질문 풀도 같은 오류. 채팅 템플릿 파서와 모델 출력의 불일치로 보이며 원인은 확인하지 않았다.
- **Mi:dm 2.0 Mini** 는 최신 llama.cpp-내장 템플릿에서도 여전히 대부분을 DONT_KNOW 로 분류해, 서빙 문제가 아닌 모델 특성으로 판단한다.
- **Kanana-2-3B** 는 최신 llama.cpp 에서 1차 실험의 깨진 출력은 해결됐지만, 모름·재설명 인식 실패와 근거 날조로 품질은 최하위다.

4.5 JSON 스키마 강제 효과 (Qwen3 4B)

지표	자유 출력 (1차, Ollama)	JSON 스키마 강제 (llama.cpp)
질문 풀 파싱 성공	90%	100%
긴 문맥 질문 풀	2/2	2/2
질문 풀 품질 (Claude)	2.80	2.40
코칭 수치 날조	0%	11.1%

형식 오류는 없어졌지만 **내용 품질은 오히려 떨어졌다**. 소형 모델에서 스키마 강제는 "파싱은 되는데 틀린 내용"을 늘릴 수 있어, 단독 해결책이 아니다.

4.6 중형 MoE 를 이 서버에서 나눠 돌렸을 때 (참고용 속도)

모델 (양자화)	파일	GPU + 컨테이너 RAM	프롬프트 처리	생성	꼬리질문 중간값	질문 풀 중간값
Gemma 4 26B-A4B (IQ3_S)	11.3GB	5.3GB + 6.3GB	90~181 tok/s	15~16 tok/s	7.6s	64.5s
Qwen3.6-35B-A3B (Q2_K_XL)	12.3GB	3.9GB + 6.5GB	131~183 tok/s	20 tok/s	6.9s	51.0s
gpt-oss-20b (MXFP4)	12.1GB	4.5GB + 5.9GB	158~178 tok/s	17 tok/s	15.6s	53.0s

- 이 서버에서는 운영용으로 느리다(1명 기준 꼬리질문 7~16초). **24GB 이상 GPU 에 전부 올리면** 리서치 벤치마크 기준 26B-A4B 는 생성 64~193 tok/s 로 올라간다.
- 실험 중 호스트 가용 메모리는 11.9~13.1GB 로 유지됐고, 스왑 사용은 3.4 → 4.5GB 로 늘었다(운영 서비스 영향 없음, 사이트 헬스체크 계속 정상).

4.7 GPU 끊김 재발 기록 (Ollama 로그, UTC)

발생	직전 배포	간격
06:49~06:58	PR #233 06:48	1~10분
07:32~07:34	PR #234 07:22	10~12분
10:02	PR #235 09:47	15분
(발생 없음)	PR #232 08:21	—

- 네 번의 배포 중 세 번 뒤에 발생했다. 발생 후 새 컨테이너(`docker run --gpus all`)와 공유 컨테이너의 `nvidia-smi` 는 모두 GPU 를 보았지만, 그 시점의 모델 로드만 CPU 로 떨어졌고 수 분 뒤 재시도하면 복구됐다.
- 리서치의 daemon-reload 가설과 부합하지만 **서버 권한(sudo) 없이 직접 재현·확인하지 못했다**.

5. 선택지별 평가

선택지	품질	꼬리질문 지연·동시성	비용	운영 리스크	판정
A. 현재 게이트웨이 Gemini 유지	◎ (4.1~4.8)	◎ 1.7s, 동시 8명에도 일정	\$0	학교 키 지속성	유지
B. 현 서버로 운영 대체 (Gemma 4 E2B/E4B, Qwen3 4B)	× (2.4~3.0)	× 피드백 중 24~47s	\$0	GPU 끊김, 공유 GPU, 노트북 전력 상한	불가
C. 현 서버를 장애 풀백으로만 (Gemma 4 E2B 전용 컨테이너)	△ (2.9)	△ 1명 1.6s, 4명 5.4s	\$0	GPU 끊김 감지·재시작 필요	필요할 때만 제한적으로
D. 중고 RTX 3090 24GB + Gemma 4 26B-A4B Q4	○~◎ (3비트에서 3.7~4.3, Q4 는 이상)	○ 벤치마크상 64~128 tok/s	~₩1.0~1.35M (+서버), 월 ~\$90 환산	중고 신뢰성, 동시성은 vLLM 필요	로컬로 간다면 1순위 후보

선택지	품질	꼬리질문 지연·동시성	비용	운영 리스크	판정
E. RTX 5090 32GB + Gemma 4 26B-A4B FP8/AWQ	◎ (추정)	◎ TTFT 1초 내, 동시 수 명	~₩5.5~6.5M, 월 ~\$205 환산	가격 변동	사용량 월 5천 세션 이상일 때
F. GPU 임대 상시 (RunPod 5090)	◎ (추정)	◎	월 \$504	월 고정비	비권장 (API 보다 비쌈)
G. 저가 오픈 모델 API (Qwen3.8-Flash, gpt-oss-120b)	미측정	제공자 의존	월 300세션 \$2~3	외부 의존	게이트웨이 대안으로 우선 검토

(◎ 우수 · ○ 양호 · △ 조건부 · ✕ 부적합)

6. 권고 및 다음 단계

- 운영은 A 유지.** 이번 실험으로 "설정만 바꾸면 현 서버로 된다"는 가능성은 닫혔다.
- 로컬 전환을 계속 추진한다면 구매 전에 임대로 검증한다.** RunPod 등에서 RTX 3090/4090/5090 을 몇 시간(시간당 \$0.22~0.99) 빌려, 이 저장소의 `run_eval.py` · `load_test.py` · `judge.py` 로 **Gemma 4 26B-A4B** 를 **Q4/FP8** 로 품질·동시성을 실측한다. 기준: 꼬리질문 Claude 판정 3.9 이상, 동시 4명 꼬리질문 3초 이내, 피드백 fan-out 중 꼬리질문 3초 이내.
- GPU 굼김 대책을 공유 서버 관리자와 적용한다.** 다른 프로젝트(devlog·devtalk·mcp)도 영향받는다. 최소한 `nvidia-smi -L` 헬스체크와 CPU 풀백 감지 경보.
- 게이트웨이 장애 풀백이 필요하다면** C 안: 공유 Ollama 가 아닌 전용 llama.cpp 컨테이너에 Gemma 4 E2B, `-np 2`, `num_ctx 8192`, `keep_alive` 상시, 헬스체크 포함. 풀백 중에는 피드백 코칭을 순차·지연 처리하도록 제한.
- 공유 Ollama 업그레이드(0.20.7 → 0.34.x)** 는 다른 프로젝트와 조율이 필요하다. 이번 실험은 별도 컨테이너로 우회했다.
- 게이트웨이 대안 비교를 끝내려면 **외부 API 키**(OpenRouter 등)로 Qwen3.8-Flash·gpt-oss-120b 를 같은 하네스로 측정한다.

7. 한계

- 3비트·2비트 품질은 하한선이다.** Gemma 4 26B-A4B·Qwen3.6-35B-A3B 는 원래 4비트 이상으로 쓰는 모델이며, 24GB GPU 에서의 품질은 이보다 높을 것으로 예상하지만 실측하지 않았다.
- 판정은 LLM 판정이며 케이스는 합성 22개다. 상위권 간 0.1~0.3점 차는 오차 범위로 본다. Gemini 판정자의 Google 계열 편향이 이번에도 관찰됐다.
- 중형 MoE 는 반복 1회, 소형은 2회 측정이다.
- 하드웨어 가격·타사 벤치마크 수치는 리서치 인용값으로 엔진·양자화·프롬프트 길이가 우리 조건과 다르다. 한국 중고가·국내 클라우드 가격 일부는 미확정이다.
- GPU 굼김 원인은 리서치 가설과 시각 상관으로만 뒷받침되며 서버 권한 없이 재현하지 못했다.
- Kanana-2-30B 는 4비트 파일만 공개되어 있어 이 서버 메모리에 맞추려 2비트로 재양자화했고, 그 결과가 깨져 품질을 측정하지 못했다.

8. 서버에 남긴 상태

항목	상태
테스트 컨테이너 <code>stackup-llmtest</code>	삭제함
llama.cpp 이미지	<code>ghcr.io/ggml-org/llama.cpp:server-cuda (4.35GB)</code> , <code>:full</code> 남아 있음

항목	상태
모델 파일 <code>/home/stackup/llm-models</code>	Gemma 4 E2B-E4B-26B-A4B, Qwen3.6-35B-A3B, gpt-oss-20b, Kanana-2-30B Q4-Q2 — 약 65GB 남아 있음 (디스크 여유 540GB+)
CUDA 커널 캐시 <code>/home/stackup/nvccache</code>	남아 있음
공유 Ollama	설정·버전 변경 없음 (1차 실험 때 추가한 모델·네트워크 연결은 그대로)
GPU 원격 측정 프로세스	종료함

9. 재현

```
# 테스트 서버 (호스트). 공유 Ollama 모델은 먼저 언로드
docker run -d --name stackup-llmtest --gpus all --memory 6g --network stackup_default \
-v /home/stackup/llm-models:/models:ro ghcr.io/ggml-org/llama.cpp:server-cuda \
-m /models/gemma-4-E2B-it-Q4_K_M.gguf --host 0.0.0.0 --port 8080 --jinja --alias testmodel \
-ngl 99 --fit off -np 4 -c 32768 -fa on -ctk q8_0 -ctv q8_0 --cache-ram 1024

# MoE CPU 오프로드 예시
docker run -d --name stackup-llmtest --gpus all --memory 11g --network stackup_default \
-v /home/stackup/llm-models:/models:ro ghcr.io/ggml-org/llama.cpp:server-cuda \
-m /models/gemma-4-26B-A4B-it-UD-IQ3_S.gguf --host 0.0.0.0 --port 8080 --jinja --alias testmodel \
-ngl 99 --n-cpu-moe 24 --fit off -np 1 -c 8192 -fa on -b 2048 -ub 2048 -t 6 --cache-ram 0

# 평가 (stackup-ai 컨테이너 안, llm_eval 디렉터리)
NOTHINK='{"chat_template_kwargs": {"enable_thinking": false}}'
python run_eval.py --label lcpp-gemma4-e2b --base-url http://stackup-llmtest:8080/v1 --api-key x \
--model testmodel --reps 2 --question-reps 2 --extra-body "$NOTHINK" --out /tmp/deep/lcpp-gemma4-e2b.jsonl
python run_eval.py --label lcpp-qwen3-4b-jsonschema ... --suites coaching,questions --constrain-json
python load_test.py --label lcpp-gemma4-e2b-np4 --base-url http://stackup-llmtest:8080/v1 --api-key x \
--model testmodel --extra-body "$NOTHINK" --out /tmp/deep/load-lcpp-gemma4-e2b-np4.jsonl
python analyze.py /tmp/deep/lcpp-*.jsonl > auto-metrics-summary.json
python judge.py --out judge.jsonl /tmp/deep-j/*.jsonl > judge-table.json
```

부록. 출력 예시

A.1 이력서와 다른 답변 (f-infra-fact-error)

자원자: "HPA 는 메모리 50% 를 기준으로 잡았습니다... 피크 대응은 따로 한 건 없고..." (이력서: CPU 70%, CronJob 사전 스케일아웃)

모델	꼬리질문
Gemma 4 26B-A4B (3비트)	이력서에는 트래픽 피크 대비 사전 스케일아웃을 위해 CronJob을 운영했다고 적혀 있는데, 답변하신 내용과 차이가 있네요. 다시 설명해 주시겠어요?
Qwen3.6-35B-A3B (2비트)	메모리 50% 기준의 구체적인 근거와, 사전 스케일아웃을 미적용한 이유를 설명해 주세요. (불일치 농침)
Gemma 4 E4B	HPA 기준을 메모리 50%로 잡으셨다고 했는데, 이 서비스의 메모리 사용량이 다른 리소스 대비 현저히 높다는 근거는 무엇인가요? (불일치 농침)
Gemma 4 E2B	HPA 기준을 메모리 50%로 설정하신 구체적인 근거와, 사전 스케일아웃을 병행하지 않은 이유를 기술적으로 설명해 주시겠어요? (불일치 농침)
Kanana-2-3B	HPA 기준(CPU 50%)과 트래픽 피크 대응(스케일아웃) 설계 방식을 설명하세요. (수치 오기, 명령조)

A.2 좋은 답변 (f-strong-backend)

모델	꼬리질문
Gemma 4 26B-A4B (3비트)	결제 키에 유니크 제약을 걸어 중복을 막는 방식이, 만약 PG사가 동일한 먹등 키가 아닌 매번 새로운 키를 생성해 재전송한다면 대응이 가능할까요?
Gemma 4 E4B	먹등 키가 PG사의 재전송 같은 외부 요청 중복을 막는다면, Outbox 패턴은 어떤 종류의 '내부' 시스템 실패 케이스를 방어하는 것인가요?
Gemma 4 E2B	먹등 키와 Outbox 패턴을 함께 사용하신 구체적인 시나리오와, 각각이 막고자 했던 실패 케이스를 기술적인 관점에서 다시 설명해 주시겠어요? (직전 질문 반복)
Kanana-2-3B	두 가지 패턴을 각각 왜 썼고, 각각이 어떤 실패 케이스를 막는지 구체적으로 설명하세요. (직전 질문 반복)

A.3 재설명 요청 (f-clarification)

모델	의도	재설명
Gemma 4 26B-A4B (3비트)	CLARIFICATION	HPA의 CPU 임계치를 70%로 설정한 이유와, 트래픽 급증 시점에 미리 서버를 늘려둔(사전 스케일아웃) 이유를 각각 나누어 설명해 달라는 의미입니다.
Gemma 4 E4B	CLARIFICATION	HPA 기준을 CPU 70%로 잡은 근거와 트래픽 피크 시 사전 스케일아웃을 병행한 이유에 대해 다시 설명해 주시겠어요? (쉬워지지 않음)
Kanana-2-3B	NORMAL (오분류)	HPA 기준을 CPU 70%로 잡으신 근거와, 트래픽 피크에 사전 스케일아웃을 병행한 이유를 설명해 주세요.